BQ-NCO: Bisimulation Quotienting for Efficient Neural Combinatorial Optimization

Darko Drakulic, Sofia Michel, Florian Mai*, Arnaud Sors, Jean-Marc Andreoli
Naver Labs Europe
firstname.lastname@naverlabs.com

总结

摘要

- OOD泛化能力仍然是NCO求解器这种end-to-end方法的难点。本文提出了COPs作为MDP的一种新表述，能够有效利用COPs问题共有的对称性来提高求解器OOD泛化的鲁棒性。
- Construction方法可以表述为direct-MDP，缺点是状态空间（任何部分解）过于庞大且冗余。
  - 在direct-MDP中，state是部分解的历史记录。对于同一个“决策情景”（剩余解），可能存在无数个不同的历史路径到达该情景。
  - 利用某种方法识别这些决策意义上等价的状态，并将它们合并，大幅减少状态空间的规模，从而提高学习效率和泛化能力。
- 本文基于互模拟商化（Bisimulation Quotienting，BQ）实现状态空间约简，对于具有**递归性质**的组合优化问题，状态缩减能够利用这些问题的对称性优化MDP的求解。
- GitHub：https://github.com/naver/bq-nco

研究问题

构造性NCO方法能够自然地建模为MDP过程，但构建合适的MDP会因具体COPs问题而不同。

将组合优化问题建模为马尔可夫决策过程

> 将COPs实例表示为：$\min\limits_{x\in X} f(x)$，其中$X$是有限、非空的**可行解集**，$f$为**目标函数**，是定义域包含$X$的实值函数。
> $\mathcal{X}$表示给定COP问题的所有部分解，并且$X\subset\mathcal{X}$。$\mathcal{X}$配备有操作$\circ$和中性元素（单位元、空部分解）ϵ。
> 对于部分解x和y，$x\circ y$表示先执行x的一系列构造步骤再执行y的一系列构造步骤得出的结果。
> $\mathcal{Z}\in \mathcal{X}$表示由$\epsilon$仅经过一步构造得到的部分解的子集，并将$\mathcal{Z}$中元素称为$step$。
> **定义1**（解空间）：称四元组$(\mathcal{X}, \circ, \epsilon, \mathcal{Z})$为解空间，其中：
>
> - $(\mathcal{X},\circ,\epsilon)$构成$monoid$(幺半群)。
> - 步骤集$\mathcal{Z}\subset \mathcal{X}$ \ ${\epsilon}$是$\mathcal{X}$的生成元。
> - $\mathcal{X}$中任一元素都具有有限个（大于0）步骤分解：$\forall x \in \mathcal{X}, , 0 < \left| \left\{ z_{1:n} \in \mathcal{Z}^n : , x = z_1 \circ \cdots \circ z_n \right\} \right| < \infty.$

> 给定包含X的解空间$\mathcal{X}$，求解COP实例(f, X)等价于寻找步骤序列$z_{1:n}$，使得$z_1 \circ \cdots \circ z_n \in \arg\min_{x \in \mathcal{X}} f(x)$，这可以很自然地建模为马尔可夫决策过程。

直接MDP

> 给定解空间$(\mathcal{X},\circ,\epsilon,\mathcal{Z})$，考虑所有实例$(f, X)$构成的集合$\mathcal{F}_\mathcal{X}$，其中：
>
> - 可行解集X是$\mathcal{X}$的一个有限、非空的子集；
> - 目标函数$f\in \mathbb{R}^\mathcal{X}$是定义在整个解空间$\mathcal{X}$上的实值函数，它对任何部分解都是良定义的。
>
> 对给定实例$(f,X)\in\mathcal{F}*mathcal{X}$，有**直接马尔可夫决策过程（Direct-MDP）$\mathcal{M}{(f,X)}$**:
>
> - **状态空间**$\bar{X} = { x \in \mathcal{X} : \exists y \in \mathcal{X}, \ x \circ y \in X }$，是所有**能扩展为可行解**的部分解的集合。
> - **动作空间**为$\mathcal{Z}\cup {\epsilon}$，一个动作可以是步骤也可以是中性动作。
> - 状态转移是确定性的，并可由以下两条规则的标记转移系统表示（每条转移边上的标签由其"动作-奖励"对构成，分别置于转移箭头的上下方），$x\in \bar{X}$是状态，$z\in \mathcal{Z}$是步骤：
> - $x \xrightarrow[f(x) - f(x \circ z)]{z} x \circ z \text{ if } x \circ z \in \bar{X}$
> - $x \xrightarrow[0]{\epsilon} x \text{ if } x \in X$
>
> 直接MDP有以下三种性质：
>
> - 有限动作集：从任意状态出发，允许执行的动作数量是有限的（即使步骤集$\mathcal{Z}$是无限的情况），因此确保了$\mathcal{M}_{(f,X)}$属于离散动作MDP。
> - 无死锁状态：从任意状态出发，都至少存在一个可执行动作。确保了能够判定部分解可以被扩展为可行解。
> - 良定义的回报与轨迹结果：在$\mathcal{M}_{(f,X)}$任何无限长的轨迹中，只有有限次转移涉及步骤(step)动作，其余所有转移都是中性动作。
>
> **命题1（直接MDP的正确性）：** 给定解空间$\mathcal{X}$和实例$(f,X)\in \mathcal{F}*mathcal{X}$，令$*mathcal{M}{(f,X)}$为直接MDP。则集合 $\arg min_{x∈X} f(x)$ （即原问题的最优解集）恰好等于满足以下条件的解 x 的集合：存在一个 $\mathcal{M}_{(f,X)}$ 的最优策略 $π$，使得 x 是在策略 $π$ 指导下从初始状态 ϵ 出发的一条轨迹的结果。 这一结果表明，一个COP实例的最优解与该实例的Direct-MDP的最优策略之间存在着精确的对应关系。

方法

互模拟商

状态信息和对称性

令$(\mathcal{X},\circ,\epsilon,\mathcal{Z})$为解空间，$\mathcal{M}{(f,X)}$是实例$(f,X)\in\mathcal{F}{\mathcal{X}}$的直接MDP。在$\mathcal{M}{(f,X)}$的轨迹中，每个非中性动作$z$使状态从$x$增长到$x\circ z$。对于许多COPs问题来说，这表示状态信息在增加的同时可选择的动作在减少，这是反直觉的。状态所携带的信息与其所支持的决策复杂度之间存在失配的问题。

而部分解$y\in \mathcal{X}$可同时看作部分解上的操作$: x \mapsto x \circ y$，对操作数进行扩展，也可看作在问题实例上的操作$(f, X) \mapsto (f * y, X * y)$，其中$(f * y)(x) = f(y \circ x) \quad \text{and} \quad X * y = \{ x \mid y \circ x \in X \}$。
实际上，$(f * y, X * y)$被称作实例(f,X)在构建好部分解y后的尾子问题。对于给定的尾子问题 $(f^', X^')\in \mathcal{F}$ $\mathcal{X}$，可能存在多组实例$(f, X) \in \mathcal{F}_\mathcal X$与部分解 $x \in \bar X$的配对，使得等式 $(f * x, X * x) = (f^', X^')$ 成立。
对于MDP策略，这是一个强对称性。直觉上，这意味着最佳策略应为这些无限多个（实例 - 部分解）对采取相同的动作。

互模拟商MDP

> 状态空间：实例集$\mathcal{F}_\mathcal X$（任意规模、分布实例）。动作空间：$\mathcal{Z}\cup \{\epsilon\}$。
> 状态转移仍是确定性的，且可用两项规则表述： $(f, X) \xrightarrow[f(\epsilon) - f(z)]{z} (f * z, X * z) \text{ if } X * z \neq \emptyset \quad \text{and} \quad (f, X) \xrightarrow[\epsilon]{0} (f, X) \text{ if } \epsilon \in X.$
>
> **命题2（BQ-MDP的正确性）：** 令$\mathcal{M}$是解空间$\mathcal{X}$的BQ-MDP，$(f,X)\in \mathcal{F}$*$\mathcal X$为一个实例。集合$\arg min*{x∈X} f(x)$ 恰好等于满足以下条件的解 x 的集合：存在一个 $\mathcal{M}$ 的最优策略 $π$，使得 x 是在策略 $π$ 指导下从 (f,X) 出发的一条轨迹的结果。 **对模型架构的影响： 从Direct-MDP的角度出发**，学习到的是**基于整个输入实例条件**下的通用MDP，即$P(\cdot | the \ whole \ input \ instance)$，类似于goal-conditioned强化学习。 典型的模型架构也由计算输入实例嵌入的编码器和利用实例嵌入与当前部分解来计算下一个动作的解码器组成。 在一条轨迹的滚动过程中，编码器仅需做一次计算。 **从BQ-MDP的角度出发**，对整个解空间仅需学习一个无条件MDP。并且不再需要区分编码器和解码器。但这样一来模型在每一步构造中都相当于在处理新的实例。

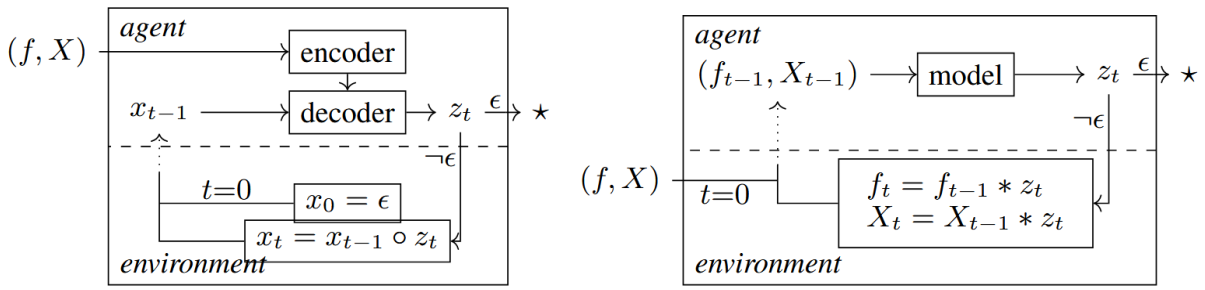

图1. 直接MDP（左）和BQ-MDP（右）的策略模型架构。

实例参数化与递归

BQ-MDP中，实例根据公式$X' = X * z $和$f' = f * z$在每一步$z$都会进行更新。为实现BQ-MDP，关键要求是$（f'，x'）$可以在与$（f，x）$相同的参数空间中表示。**满足尾递归性质的COPs就符合这一要求。**

策略学习

使用交叉熵损失通过模仿专家轨迹进行模型训练。

模型架构

> 首先，将节点坐标通过**线性层**进行嵌入；
> 不适用位置编码，而是将可学习的起点及终点编码向量与起点和终点的特征嵌入进行相加；
> 使用ReZero归一化； 最后，线性层将最后一个注意力块的输出投影到大小为N的向量，并在softmax前掩蔽掉其中的起点和终点的值。

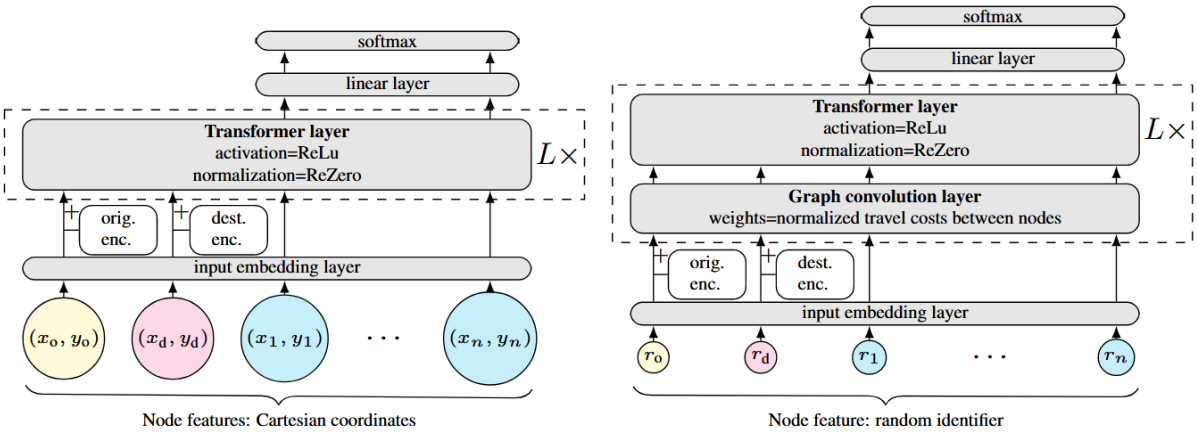

图2. TSP（左）和ATSP（右）的BQ-MDP策略模型架构。起点（黄）、终点（红）、其它（蓝）。

实验

实验设备： Single Nvidia Tesla V100-S GPU with 24GB memory， Intel(R) Xeon(R) CPU E5-2670 with 256GB memory。
实验设置：

- 训练集：对于路由问题，本文方法和基线均在规模100的合成实例上进行训练；对基于perceiver的模型，测试时将最近邻规模限制为250；
- 超参及训练：模型层数9、注意力头数12、嵌入维度192、前馈层维度512；训练集大小为100w；训练过程中从标签路径中采样子路径进行学习；batch_size为1024，训练1024个epochs；学习率7.5e-4，每50个epochs衰减0.98；对于CVRP，输入增加节点需求维度，以及当前车辆容量维度；softmax之前，对起点终点与不满足约束节点进行掩蔽；
- CVRP容量分别是50，80，100，250；
- TSP参照Concorde、CVRP参照LKH。

		Test (10k inst.)		Generalization (128 instances)					
		N=100		N=200		N=500		N=1000	
		opt. gap	time	opt. gap	time	opt. gap	time	opt. gap	time
TSP	Concorde	0.00%	38m	0.00%	2m	0.00%	40m	0.00%	2.5h
	OR-Tools	3.76%	1.1h	4.52%	4m	4.89%	31m	5.02%	2.4h
	Att-GCN+MCTS*	0.04%	15m	0.88%	2m	2.54%	6m	3.22%	13m
	DIFUSCO G+2opt*	0.24%	-	-	-	2.40%	4m	3.40%	12m
	SGBS (10,10)	0.06%	15m	0.67%	1m	11.42%	20m	25.25%	2.9h
	AM bs1024	2.51%	20m	6.18%	1m	17.98%	8m	29.75%	31m
	TransTSP bs1024	0.46%	51m	5.12%	1m	36.14%	9m	76.21%	37m
	MDAM bs50	0.39%	45m	2.04%	3m	9.88%	13m	19.96%	1.1h
	POMO augx8	0.13%	1m	1.57%	5s	20.18%	1m	40.60%	10m
	DIMES RL+S*	-	-	-	-	16.07%	1m	17.69%	2m
	Sym-NCO s100	0.64%	13s	2.28%	2s	21.64%	13s	37.51%	2m
	BQ-perceiver G	0.97%	1m	2.09%	2s	5.22%	8s	8.97%	22s
	BQ-transformer G	0.35%	2m	0.54%	9s	1.18%	55s	2.29%	2m
	BQ-transformer bs16	**0.01%**	32m	**0.09%**	3m	**0.55%**	15m	**1.38%**	38m
CVRP	LKH	0.00%	15.3h	0.00%	30m	0.00%	1.3h	0.00%	2.8h
	HGS	-0.51%	15.3h	-1.02%	30m	-1.25%	1.3h	-1.10%	2.8h
	OR-Tools	9.62%	1h	10.70%	3m	11.40%	18m	13.56%	43m
	AM bs1024	4.18%	24m	7.79%	1m	16.96%	8m	86.41%	31m
	MDAM bs50	2.21%	56m	4.33%	3m	9.99%	14m	28.01%	1.4h
	POMO augx8	0.69%	1m	4.77%	5s	20.57%	1m	141.06%	10m
	Sym-NCO s100	1.46%	15s	4.84%	3s	18.64%	13s	119.60%	9m
	SGBS (4,4)	**0.08%**	15m	2.47%	1m	14.98%	20m	151.07%	2.9h
	BQ-perceiver G	5.63%	1m	5.49%	3s	6.39%	8s	10.21%	24s
	BQ-transformer G	2.79%	2m	2.81%	9s	3.64%	55s	5.88%	2m
	BQ-transformer bs16	0.95%	32m	**0.77%**	3m	**1.04%**	15m	**2.55%**	38m
OP (DIST.)	EA4OP	0.00%	1.4h	0.00%	3m	0.00%	11m	0.00%	45m
	AM bs1024	2.19%	17m	8.04%	1m	20.73%	4m	29.96%	15m
	MDAM bs50	0.69%	32m	2.98%	49s	15.36%	4m	26.55%	15m
	SymNCO s200	0.45%	4m	3.39%	2s	15.23%	37s	26.95%	2m
	BQ-transformer G	-0.15%	2m	0.62%	8s	3.26%	42s	8.40%	8.9m
	BQ-transformer bs16	**-1.19%**	35m	**-0.84%**	2.1m	**1.04%**	21m	**4.81%**	2.2h
ATSP	LKH	0.00%	18m	0.00%	29s	0.00%	2.3m	0.00%	9.4m
	MatNet s128†	**0.93%**	45m	124.20%	4m	-	-	-	
	BQ-GCN-transformer G	1.27%	1m	1.56%	4s	4.22%	12s	11.59%	14s
	BQ-GCN-transformer bs16	0.96%	19m	**1.41%**	1m	**2.43%**	3m	**8.26%**	7m

表1. 使用greedy rollout或beam search的BQ模型与经典或神经求解器对比实验结果。

	MDAM	POMO	BQ (ours)	
Size	bs50	x8	greedy	bs16
<100	3.06%	0.42%	0.34%	**0.06%**
100-200	5.14%	2.31%	1.99%	**1.21%**
200-500	11.32%	13.32%	2.23%	**0.92%**
500-1K	20.40%	31.58%	2.61%	**1.91%**
>1K	40.81%	62.61%	6.42%	**5.90%**
All	19.01%	26.30%	3.30%	**2.55%**

	MDAM	POMO	BQ (ours)	
Set (size)	bs50	augx8	greedy	bs16
A (32-80)	6.17%	4.86%	4.52%	**1.18%**
B (30-77)	8.77%	5.13%	6.36%	**2.48%**
F (44-134)	16.96%	15.49%	6.63%	**5.94%**
M (100-200)	5.92%	4.99%	3.58%	**2.66%**
P (15-100)	8.44%	14.69%	3.61%	**1.54%**
X (100-1K)	34.17%	21.62%	9.94%	**7.22%**
All (15-1K)	22.36%	15.58%	7.62%	**4.83%**

表2. TSPLib、CVRPLib上的实验结果。

结论

我们这种方法与所有构建式方法的一个共同局限性在于，它只能处理那些在整个构建过程中**易于确保可行性**的问题。为了解决具有更复杂全局约束的问题，**结合学习和约束规划的方法**可能是一个有前景的方向。虽然在相对较小的实例上进行训练使我们能够使用模仿学习，但我们提出的马尔可夫决策过程（MDPs）及其相关模型也可以通过强化学习进行训练。这将特别有趣的是，将我们的框架从确定性扩展到随机COPs。

附录

Impact of k-nearest-neighbor heuristic on model performance

正如第 6 节所述，通过使用 k 近邻启发式方法来限制搜索空间，可以减少我们模型的推理时间。对于贪婪展开和束搜索策略，在每一步中，都可以通过仅考虑一定数量的相邻节点来缩减剩余的图。表 4 展示了在 TSP 和 CVRP 上的实验，我们在不同的起始点的近邻数量下应用了该模型。这种方法明显减少了执行时间，而且在某些情况下甚至在最优性差距方面提高了性能。请注意，选择近邻的标准不一定是距离，而是与该问题的一些贪婪启发式相同的度量标准。例如，对于背包问题，可以将物品限制为价值（或价值/重量比）最高的 k 个物品。

		TSP				CVRP			
		Greedy		Beam size 16		Greedy		Beam size 16	
N=500	full graph	1.091%	2m	0.572%	28m	3.951%	2m	1.503%	28m
	250 KNNs	1.186%	1m	0.550%	15m	3.645%	1m	1.040%	15m
N=1000	full graph	2.141%	14m	1.412%	3.5h	6.282%	15m	3.660%	5.4h
	500 KNNs	2.086%	7m	1.348%	2.7h	6.330%	10m	3.382%	2.7h
	250 KNNs	2.294%	2m	1.379%	38m	5.883%	2m	2.552%	38m

Table 4: Experimental results with different numbers N of nearest-neighbors during the inference.

笔记

Bisimulation（互模拟） 是一个强大的概念，用于定义MDP状态之间的**等价关系**。两个状态 s1 和 s2 是 **bisimilar** 的，当且仅当：

1. 即时奖励相等：对于任何动作，从这两个状态出发获得的即时奖励相同。
2. 概率转移到等价类：对于任何动作，从这两个状态出发，转移到任何未来状态等价类的概率分布相同。

它关注的不是状态本身是否相同，而是它们未来的行为模式是否完全相同。
Bisimulation Quotienting（互模拟商化） 就是这个过程的专有名词：

- 首先，根据bisimulation关系将原始MDP的所有状态划分成若干个等价类。每个类包含所有行为模式相同的状态。
- 然后，构建一个新的MDP，称为 商MDP（Quotient MDP）。
  - 这个新MDP的每个状态就代表原始MDP中的一个等价类。
  - 动作、奖励和转移概率都在这些等价类之间进行定义。

本文应用Bisimulation的理论，并证明了：

- 对于直接MDP中的两个状态（部分解）x1 和 x2，如果它们诱导出的**尾子问题（Tail Subproblem）** $(f*x1, X*x1)$ 和 $(f*x2, X*x2)$ 是相同的，那么这两个状态就是 bisimilar 的。
- 因此，尾子问题本身就成为了Bisimulation等价类的完美代表。新MDP（BQ-MDP）的状态就是这些尾子问题实例。

参考文献(后续阅读)

> **不同COPs问题MDP构建**
> Wouter Kool, Herke van Hoof, and Max Welling. **Attention, Learn to Solve Routing Problems!** In International Conference on Learning Representations, 2019.
> Cong Zhang, Wen Song, Zhiguang Cao, Jie Zhang, Puay Siew Tan, and Chi Xu. **Learning to dispatch for job shop scheduling via deep reinforcement learning.** In Proceedings of the 34th International Conference on Neural Information Processing Systems, NIPS'20, pages 16211632, Red Hook, NY, USA, December 2020. Curran Associates Inc. ISBN 978-1-71382-954-6.
> Yuan Jiang, Zhiguang Cao, and Jie Zhang. **Solving 3D Bin Packing Problem via Multimodal Deep Reinforcement Learning.** In Proceedings of the 20th International Conference on Autonomous Agents

and MultiAgent Systems, AAMAS '21, pages 1548–1550, Richland, SC, May 2021. International Foundation for Autonomous Agents and Multiagent Systems. ISBN 978-1-4503-8307-3.

Step-wise approaches Bo Peng, Jiahai Wang, and Zizhen Zhang. **A Deep Reinforcement Learning Algorithm Using Dynamic Attention Model for Vehicle Routing Problems.** In Kangshun Li, Wei Li, Hui Wang, and Yong Liu, editors, Artificial Intelligence Algorithms and Applications, Communications in Computer and Information Science, pages 636–650, Singapore, 2020. Springer. ISBN 9789811555770. doi: 10.1007/978-981-15-5577-0_51.
Liang Xin, Wen Song, Zhiguang Cao, and Jie Zhang. **Step-Wise Deep Learning Models for Solving Routing Problems.** IEEE Transactions on Industrial Informatics, 17(7):4861–4871, July 2021. ISSN 1941-0050. doi: 10.1109/TII.2020.3031409.
Liang Xin, Wen Song, Zhiguang Cao, and Jie Zhang. **Multi-Decoder Attention Model with Embedding Glimpse for Solving Vehicle Routing Problems.** Proceedings of the AAAI Conference on Artificial Intelligence, 35(13):12042–12049, May 2021. ISSN 2374-3468. doi: 10.1609/aaai.v35i13.17430.

Thomas Bachlechner, Bodhisattwa Prasad Majumder, Henry Mao, Gary Cottrell, and Julian McAuley. **ReZero is all you need: Fast convergence at large depth.** In Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence, pages 1352–1361. PMLR, December 2021.
Xavier Bresson and Thomas Laurent. **The Transformer Network for the Traveling Salesman Problem.** arXiv:2103.03012 [cs], March 2021.
Jinho Choo, Yeong-Dae Kwon, Jihoon Kim, Jeongwoo Jae, Andre Hottung, Kevin Tierney, and Youngjune Gwon. **Simulation-guided Beam Search for Neural Combinatorial Optimization.** In NeurIPS 2022, 2022.

Edward Groshev, Maxwell Goldstein, Aviv Tamar, Siddharth Srivastava, and Pieter Abbeel. **Learning Generalized Reactive Policies Using Deep Neural Networks.** Proceedings of the International Conference on Automated Planning and Scheduling, 28:408–416, June 2018. ISSN 2334-0843. doi: 10.1609/icaps.v28i1.13872.